

ফাইনাল ব্রুশ্ট · V2

বাংলা ইশারা ভাষা → টেক্সট ও কণ্ঠ

অক্ষর · শব্দ · বাক্য — সব চিনে রিয়েল-টাইমে বলবে। On-device recognition + Gemini ভাষা স্তর, এক ডায়াল ইঞ্জিন PC/iOS/Android সবখানে। ২ জনের টিমের জন্য সাজানো।

On-device
রিয়েল-টাইম চেনা

~৫০ms
নেটোর্স

২ জন
ডেভেলপার

~\$0
ডেমো খরচ

8
প্রোটফর্ম

BdSL · MediaPipe + TensorFlow.js + Gemini + TTS | স্কোপ অক্ষর + শব্দ + বাক্য | জুন ২০২৬

এটা তোমার পছন্দ অনুযায়ী সাজানো ফাইনাল প্ল্যান — **full স্কোপ** (অক্ষর, শব্দ ও বাক্য), **সবচেয়ে fast রিয়েল-টাইম** পথ কিন্তু **কম খরচ**, এবং **ডেমোর জন্য একদম ফ্রি**। ভেতরে আছে — চূড়ান্ত আর্কিটেকচার ও কেন এটাই সেরা, পুরো **data flow, cross-platform** ডেলিভারি, ফিচার, ধাপে-ধাপে রোডম্যাপ, কমিট প্ল্যান, ২ জনের কাজ ভাগ ও খরচের হিসাব।

তুমি ফাইনাল স্টেজ চাও — সিস্টেমটা **অক্ষর, শব্দ ও পূর্ণ বাক্য** সব চিনে কঠে বলবে। কাজটা তিন স্তরে, একটার ওপর আরেকটা গড়ে তোলা হবে (একসাথে নয়):

স্তর ১ অক্ষর finger-spelling, static — সহজ ভিত্তি	স্তর ২ শব্দ dynamic gesture, sequence মডেল	স্তর ৩ বাক্য + কঠ শব্দ জুড়ে স্বাভাবিক বাণেশ
---	--	--

তোমার শর্ত ছিল — একদম রিয়েল-টাইম, ভালো পিডি, কিন্তু বেশি হাসেল নয়। দুটো একসাথে পেতে এই ডিজাইন:

 **সিদ্ধান্ত**

চেনা (VISION + MODEL) On-device ব্রাউজারেই — MediaPipe JS + TF.js। Network hop নেই, তাই সবচেয়ে fast (~৫০ms)।	ভাষা (শব্দ → বাক্য) Gemini API শুধু বাক্য সুন্দর করতে, async — রিয়েল-টাইম আটকায় না।	ডেভিভ্যারি এক ওয়েব ইঞ্জিন PC/iOS/Android সবখানে। আলাদা plugin/ সার্ভার লাগে না।
--	---	---


কেন backend সার্ভার নয় ?

সার্ভারে প্রতি ফ্রেম পাঠানো-আনায় network delay বাড়ে — on-device তার চেয়ে fast। আর সার্ভার চালু রাখা, স্কেল করা ২ জনের জন্য extra হাসেল।

কেন native Flutter plugin নয় ?

MediaPipe-এর Flutter সাপোর্ট খণ্ডিত — Android/iOS/web-এ আলাদা প্যাকেজ। ওয়েব ইঞ্জিন একবার লিখলেই সব জায়গায় চলে, কাজ অর্ধেক।

ভারী ও গতির অংশটা (নীল) ফোন/পিসিতেই চলে; শুধু ভাষা পলিশ (বেগুনি) API-তে যায়:



✓ দ্রুত আর নির্ভুল — দুটোই

চেনা অক্ষর/শব্দ জিনে সাথে সাথে দেখাবে (on-device, ~৫০ms)। সুন্দর পূর্ণ বাক্য ও কণ্ঠ আসবে এক beat পরে — অনেকটা লাইভ ইন্টারপ্রিটরের মতো।

এতে রিয়েল-টাইম ফিল নষ্ট হয় না, কারণ ব্যবহারকারী চেনা শব্দ তখনই দেখছে; Gemini-র polish ব্যাকগ্রাউন্ডে চলে। Internet না থাকলেও অন্তত অক্ষর/শব্দ চেনা ও Web Speech কণ্ঠ চলেবে।

কঠিন অংশটা (ওয়েব ইঞ্জিন) একবার বানাও — তারপর তিনভাবে সবার কাছে পৌঁছাও:

ওয়েব ইঞ্জিন

MediaPipe JS + TF.js + Gemini +
TTS
(একবার বানাও)



PC ব্রাউজার

তোমার "PC website" — Chrome/Edge/Safari-তেই চলে



PWA (iOS + Android)

ফোনে install হয়, আপনের মতো, অফলাইনেও খোলে



Flutter shell (optional)

App Store / Play-তে দিতে চাইলে WebView-এ ইঞ্জিন

ছোট সতর্কতা — iOS

iOS-এ in-app WebView-এ ক্যামেরা মাঝে মাঝে ঝামেলা করে। সম্ভব সমাধান: iOS-এ Safari-তে PWA হিসেবে চালাও (ক্যামেরা ঠিক কাজ করে), Flutter shell পরে যোগ করে।

ডেটা (ON-DEVICE)

MediaPipe Tasks (JS/WASM) + TensorFlow.js

ভাষা স্তর

Gemini API — Flash-Lite, ফ্রি tier

কণ্ঠ (TTS)

Web Speech API (ফ্রি) → Cloud/Gemini TTS (upgrade)

আপ / UI

Next.js + TS + Tailwind + PWA + Flutter shell

মডেল ট্রেনিং

Python + Kaggle/Colab ফ্রি GPU → export to TF.js

হোস্টিং + কোড

Vercel (ফ্রি) · Git + GitHub

রেডিমেড BdSL মডেল নেই — তাই একটা **হালকা মডেল train** করতে হবে। ভয়ের কিছু নেই: MediaPipe প্রতি ফ্রেমে হাতের ছোট **landmark vector** দেয় (raw pixel নয়), তার ওপর ছোট LSTM train হয় — Kaggle/Colab-এর ফ্রি GPU-তে কয়েক ঘণ্টায়।

"Dictionary" = ডেটাসেটগুলোই (label already বাংলায়, তাই বাংলা কনভার্সন স্ক্রিপ্ট-ইন):

Ishara-Lipi

প্রথম ওপেন BdSL ক্যারেক্টার সেট

BAUST Lipi

৩৬ অক্ষর * ১৮,০০০ ছবি

BdSL36

৩৬ বাংলা অক্ষর/সংখ্যা

BdSL Words

১০টি দৈনন্দিন শব্দ

বেশি শব্দের জন্য

স্বর ২-৩ এ **vocabulary** বাড়তে তোমরা ২ জন বিজ্ঞেরা ২০-৩০টা **common** শব্দ (যেমন: পানি, খাবার, সাহায্য, ধন্যবাদ) রেকর্ড করো ভিন্ন আলো/ব্যাকগ্রাউন্ডে — এতে নির্ভুলতা ও প্রতিযোগিতার স্কের দুটোই বাড়বে।

Gemini-র কাজ: চেনা শব্দগুলোকে আভাবিক বাংলায় গাঁথা।

[অমি, স্কুল, যাওয়া]
→ "অমি স্কুলে যাচ্ছি"

prompt: "এই শব্দগুলো দিয়ে একটি শুদ্ধ বাংলা বাক্য বানাও।" **async** চলে, ফ্রি tier যথেষ্ট।

কণ্ঠ (TTS) — দুই স্তরে:

ডিস্কট: Web Speech API — ব্রাউজারেই, ফ্রি, instant (Android-এ বাংলা কণ্ঠ আছে)।

Upgrade: যেখানে কণ্ঠ নেই বা অরও ভালো চাও — Google Cloud TTS বাংলা / Gemini TTS / AI4Bharat Indic-TTS।

তিন স্তরে গড়ে তোলা — আগেরটা দাঁড়ালে পরেরটা:

স্তর ১ — ডিউ

আপে

- রিয়েল-টাইম অক্ষর চেনা (finger-spelling)
- লাইভ ক্যামেরা + হাতের landmark ওজরলে
- চেনা অক্ষর ফ্রিনে instant
- Web Speech দিয়ে অক্ষর/শব্দ উচ্চারণ
- কনফিগারেশন স্কোর

স্তর ২ — শব্দ

এক্স

- dynamic শব্দ চেনা (sequence)
- শব্দ জন্মিয়ে রাখা + hold-to-confirm
- নিজেদের রেকর্ড করা শব্দ যোগ
- সংখ্যা ও quick phrases
- ট্রান্সক্রিপ্ট সেভ/এক্সপোর্ট

স্তর ৩ — বাক্য + Wow

পেবে

- Gemini দিয়ে স্বাভাবিক বাংলা বাক্য
- পূর্ণ বাক্য কন্ঠ বলা (ভালো TTS)
- কন্ঠ/স্পিড নির্বাচন, ডার্ক মোড
- প্রাকটিস মোড (BdSL শেখানো)
- PWA install + অফলাইন মোড

- ফেজ ০ — সেটআপ**
Git রিপো, README, থেমডার, ২ জনের কলজ ভাগ, Gemini key সেট।
- ফেজ ১ — ডেটা ও landmark**
BdSL ডেটাসেট → MediaPipe দিয়ে landmark বের করা → train/test।
▶ মডেল-রেডি ডেটা
- ফেজ ২ — মডেল ট্রেনিং (অক্ষর)**
LSTM train (ফ্রি GPU) → ইন্সট্যান্সেট → TF.js-এ export।
▶ অক্ষর চেনা মডেল
- ফেজ ৩ — ওয়েব রিয়েল-টাইম ইঞ্জিন**
ব্রাউজারে MediaPipe JS + TF.js → লাইভ ক্যামেরা → instant অক্ষর + smoothing।
▶ লাইভ চেনা ব্রাউজারে
- ফেজ ৪ — শব্দ ও বাক্য**
dynamic শব্দ মডেল → শব্দ জন্মা → Gemini দিয়ে বাংলা বাক্য।
▶ শব্দ + বাক্য
- ফেজ ৫ — কন্ঠ (TTS)**
Web Speech যুক্ত → async প্রেক্ষাপট → Cloud TTS upgrade।
▶ ইশারা → কন্ঠ
- ফেজ ৬ — UI + PWA**
ক্যামেরা ফিড, লাইভ ক্যাপশন, সোটিংস, রেসপন্সিভ, PWA install।
▶ সব প্রোটোটাইপ অ্যাপ
- ফেজ ৭ — পলিশ, টেস্ট ও ডিপ্লয়**
নেটেসিসি টিউন, এরর হ্যান্ডলিং, ডেমো জিউও, Vercel ডিপ্লয় (+ Flutter shell)।
▶ প্রতিযোগিতা-রেডি, লাইভ লিংক

২ জনের এই আর্কিটেকচারে ছোট atomic কমিট ধরে আনুমানিক ৮০-১০০টি কমিট:

#	কাজ	কমিট	নমুনা কমিট মেসেজ
০	সেটআপ	৭	chore: init repo + gitignore docs: add README
১	ডেটা ও landmark	১১	feat: mediapipe landmark extraction feat: train/test split
২	মডেল ট্রেনিং (অক্ষর)	১০	feat: LSTM training feat: export to tfjs
৩	ওয়েব রিয়েল-টাইম ইঞ্জিন	১৫	feat: mediapipe js in browser feat: live prediction fix: smoothing
৪	শব্দ ও বাক্য	১৪	feat: dynamic word model feat: gemini sentence builder
৫	কন্ঠ (TTS)	৮	feat: web speech tts feat: cloud tts fallback
৬	UI + PWA	১৪	feat: caption panel feat: pwa manifest style: responsive
৭	পলিশ, টেস্ট ও ডিপ্লয়	১০	perf: reduce latency docs: demo chore: deploy vercel
মোট আনুমানিক		~৯০	পরিপূর্ণ ৮০-১০০

প্রতিটা কমিট সুন্দর রাখার নিয়ম:

ছোট, atomic কমিট

একটাই যৌক্তিক পরিবর্তন প্রতি কমিটে।

Conventional Commits

feat: fix: docs: refactor: test: chore:

ফিচার শেষেই কমিট

শেষে জমিয়ে নয়, তখনই।

Feature branch + PR

main সবসময় কাজ করা অবস্থায়।

.gitignore ঠিকঠাক

node_modules, মডেল weight, venv বাদ; বড় ফাইল LFS।

মাইলস্টোন ট্যাগ

v0.1-letters · v0.2-words · v1.0-demo

১

Vision / ML Lead

ডেটা + MediaPipe + মডেল ট্রেনিং + on-device ইঞ্জিন ইন্টিগ্রেশন (ফেজ ১-৩, শব্দ মডেল)

২

App Lead

Web/PWA/Flutter UI + Gemini ভাষা + TTS + ডিগ্রয় + ডেমো (ফেজ ৩-৭)

দুজনে নিজ নিজ feature branch + PR। ছোট টিম, তাই কঠিন অংশে (যেমন রিয়েল-টাইম টিউনিং) pair programming করো। ফেজ ৩-এ দুজনের কাজ মেনে — সেখানে একসাথে।

১২ খরচের হিসাব — ডেমো ~\$0

COST

অংশ	ইল	খরচ
Vision / চেনা	MediaPipe JS (on-device)	ফ্রি
মডেল ট্রেনিং	Kaggle / Colab GPU	ফ্রি
ভাষা স্তর	Gemini free tier (Flash-Lite)	ফ্রি · ~১৫০০/দিন
কন্ঠ (TTS)	Web Speech API	ফ্রি
হোস্টিং	Vercel	ফ্রি
ডেটাসেট	ওপেন BbSL ডেটাসেট	ফ্রি
শেষ (ডেমো/প্রতিযোগিতা)		~\$0

পরে scale করলে অল্প খরচ: Gemini paid (সঙ্গ Flash-Lite), Cloud TTS, ভালো হোস্টিং — মাসে \$৫-২০ এর মধ্যে।

১৩ ক্যামেরা ও টেস্টিং

CAMERA

কোন ক্যামেরা?

Dev/ফ্রন্ট টেস্টে **আপটপ ক্যামেরা**। ডেটা কালেকশন ও ফাইনাল টেস্ট **ফোনে** (আপ ফোনেই চলবে, ক্যামেরাও ভালো)।

Accuracy-র আসল চাবি

ভালো আলো · হাত+মুখ+শরীর ফ্রেমে · 720p+ · স্থির অবস্থান। এগুলো ক্যামেরা ব্র্যান্ডের চেয়ে বেশি জরুরি।

আলো/ব্যাকগ্রাউন্ড ভেদে নির্ভুলতা — সমাধান: বৈচিত্র্যময় ডেটা + augmentation।

দুই হাত + নুখভঙ্গি (BdSL ব্যাকরণ) — সমাধান: শুধু হাত নয়, MediaPipe Holistic ব্যবহার।

একই শব্দ বারবার ধরা — সমাধান: debounce / hold-to-confirm।

iOS WebView ক্যামেরা — সমাধান: iOS-এ Safari PWA হিসেবে চালানো।

Web Speech-এ বাংলা কণ্ঠ না থাকা (কিছু ডিভাইসে) — সমাধান: Cloud/Gemini TTS fallback।

মডেল ব্রাউজারে ভারী হওয়া — সমাধান: ছোট LSTM, quantize, GPU delegate।

শুরু করো ফেজ ০ → ১ → ২ দিয়ে — অক্ষর আপে

স্তর ১ (অক্ষর) ব্রাউজারে চলেই থাকি — শব্দ, বাক্য, কণ্ঠ — একটার ওপর আরেকটা দাঁড়িয়ে যাবে। প্রতিটা ছোট জয় পরিষ্কার মেসেজে কমিট করো। সব সম্ভব। 🚀

তথ্যসূত্র: BAUST Lipi (arXiv:2408.10518) · BdSL36 (arXiv:2110.00869) · Ishara-Lipi (ICBSLP 2018) · MediaPipe Holistic + LSTM real-time SLR (~৯২-৯৭%, ~৫০ms/frame; IJRASET 2025) · MediaPipe web/JS ও Flutter সাপোর্ট (pub.dev, MediaPipe docs) · Gemini API 3 tier — Flash/Flash-Lite, ~১৫০০ RPD (ai.google.dev, ২০২৬) · বাংলা TTS: Web Speech API, AI4Bharat Indic-TTS, bangla-tts।